

Học Đối Sánh Có Hướng Dẫn Cụm Bệnh Cho Truy Hồi Ảnh–Báo Cáo X-quang Ngực

*Clustering-Guided Contrastive Learning for
Clinically Aware Chest X-ray Image–Report Retrieval*

Diep Trung Nam

Khoa Công nghệ Thông tin, Trường Đại học ...

dieptrungnam123@gmail.com

Ngày 27 tháng 4 năm 2026

Tóm tắt nội dung

Tóm tắt (Vietnamese Abstract). Truy hồi ảnh–báo cáo X-quang ngực theo hướng học đối sánh đa phương thức (*contrastive learning*) thường gặp vấn đề *âm tính sai* (*false negative*): các ảnh và báo cáo của bệnh nhân khác nhau nhưng cùng nhóm bệnh lý bị xử lý như các cặp không liên quan, gây ra áp lực gradient sai lệch và làm suy giảm khả năng truy hồi theo ngữ nghĩa lâm sàng. Bài báo này đề xuất khung học đối sánh có hướng dẫn cụm bệnh (*clustering-guided contrastive learning framework*) nhằm giảm thiểu vấn đề trên. Mô hình kết hợp SwinV2-Base làm bộ mã hóa ảnh và Bio_ClinicalBERT làm bộ mã hóa báo cáo, ánh xạ cả hai về không gian nhúng 512 chiều dùng chung. Quá trình huấn luyện áp dụng ba giai đoạn: (1) học khớp chính xác cặp ảnh–báo cáo bằng InfoNCE đa dương tính, (2) điều chỉnh mục tiêu mềm theo độ tương đồng Jaccard có trọng số IDF theo nhóm bệnh lý, và (3) kéo các mẫu không bình thường cùng nhóm bệnh lại

gần nhau bằng hàm mất mát đối sánh có giám sát lâm sàng với lịch curriculum. Trên bộ dữ liệu IU-Xray với phân chia cấp độ bệnh nhân cố định, mô hình đạt *clinical-valid* mean R@1 = 59.86%, *cluster* mean R@1 = 69.36%, và *strict* mean R@1 = 3.85% trên tập kiểm tra. Trong 377 ca kiểm tra, 64 ca ảnh-sang-văn bản và 93 ca văn bản-sang-ảnh được xác định là *clinical rescue*: mô hình trả về kết quả top-1 khác bệnh nhân nhưng đúng về nhóm bệnh lý, minh chứng cho hiệu quả của phương pháp đề xuất.

Từ khoá: truy hồi ảnh-văn bản y khoa, học đối sánh, âm tính sai, cụm bệnh, X-quang ngực, SwinV2, ClinicalBERT.

Tóm tắt nội dung

Abstract (English). Cross-modal contrastive learning for chest X-ray image–report retrieval commonly suffers from the *false-negative* problem: image–report pairs from different patients sharing the same pathological findings are treated as hard negatives, introducing incorrect gradient pressure and degrading clinically meaningful retrieval. We propose a *clustering-guided contrastive learning framework* to mitigate this issue. Our model pairs a SwinV2-Base image encoder with a Bio_ClinicalBERT text encoder, projecting both modalities into a shared 512-dimensional embedding space via deep MLP heads. Training proceeds in three phases: (1) strict image–report alignment with multi-positive InfoNCE, (2) soft-target blending using IDF-weighted Jaccard pathology similarity, and (3) a clinical supervised contrastive loss with a curriculum schedule that pulls same-disease, non-normal pairs together without compromising exact retrieval. On the IU-Xray dataset under a fixed patient-stratified split, the proposed model (v8, 150 epochs, NVIDIA A100) achieves a *clinical-valid* mean R@1 of 59.86%, *cluster* mean R@1 of 69.36%, and *strict* mean R@1 of 3.85% on the test set. Qualitative analysis reveals 64 image-to-text and 93 text-to-image *clinical rescue* cases in the top-1, where the model retrieves a clinically related result from a different patient, demonstrating effective false-negative mitigation.

Keywords: medical image–text retrieval, contrastive learning, false negatives, pathology clustering, chest X-ray, SwinV2, ClinicalBERT.

Mục lục

1	Giới Thiệu (Introduction)	2
2	Công Trình Liên Quan (Related Work)	3
2.1	Học Đối Sánh Đa Phương Thức	3
2.2	Vấn Đề Âm Tính Sai	3
2.3	Bộ Mã Hóa Y Khoa	3
2.4	Truy Hồi Ảnh–Báo Cáo X-quang Ngực	3
3	Phương Pháp Đề Xuất (Proposed Method)	4
3.1	Biểu Diễn Dữ Liệu	4
3.2	Kiến Trúc Mô Hình	5
3.2.1	Bộ Mã Hóa Ảnh (Image Encoder)	5
3.2.2	Bộ Mã Hóa Văn Bản (Text Encoder)	5
3.2.3	Đầu Chiếu (Projection Head)	5
3.2.4	Tổng Hợp Đa View (Multi-View Attention Pooling)	5
3.2.5	Đầu Phụ Bệnh Lý (Auxiliary Pathology Heads)	6
3.3	Hàm Mất Mát Theo Phân Cấp Cụm Bệnh	6
3.3.1	Giai Đoạn 1: MultiPositive InfoNCE (Epoch 1–11)	6
3.3.2	Giai Đoạn 2: Hierarchical Clustering Loss (Epoch 12+)	6
3.3.3	Hàm Mất Mát Đối Sánh Có Giám Sát Lâm Sàng (Epoch 15+)	7
3.3.4	Hàm Mất Mát Phụ (Auxiliary Loss)	8
3.4	Lịch Curriculum Lâm Sàng	8
4	Thực Nghiệm (Experiments)	9
4.1	Bộ Dữ Liệu	9
4.2	Cài Đặt Thực Nghiệm	10
4.3	Chỉ Số Đánh Giá	11
5	Kết Quả (Results)	12
5.1	Kết Quả Định Lượng Trên Tập Kiểm Tra	12
5.2	Phân Tích Định Tính: Bucket Analysis	13
5.3	So Sánh Với Mô Hình Nền	13
5.4	Động Lực Huấn Luyện	14
6	Thảo Luận (Discussion)	14
6.1	Ý Nghĩa Của Clinical-Valid R@1 Cao	14
6.2	Hạn Chế Của Strict R@1	14
6.3	Vai Trò Của Jaccard IDF và Healthy Cluster	15
6.4	Curriculum Vs. Fixed Clinical Weight	15


6.5	Các Thành Phần Không Bất Trong V8	15
6.6	Hạn Chế	15
7	Kết Luận (Conclusion)	16
A	Cấu Hình Đầy Đủ Run V8	19
B	Phân Bố Trọng Số IDF Theo Nhóm Bệnh	20
C	Bộ Chỉ Số Đầy Đủ Tất Cả Checkpoint	20

1 Giới Thiệu (Introduction)

Truy hồi ảnh–báo cáo y khoa (*medical image–text retrieval*) là bài toán liên kết ảnh chẩn đoán với báo cáo lâm sàng tương ứng trong không gian nhúng chung. Ứng dụng thực tế bao gồm hỗ trợ bác sĩ tìm ca tương đồng, tổng hợp báo cáo tự động và xây dựng hệ thống tư vấn lâm sàng (Jing et al., 2018).

Học đối sánh đa phương thức (*multimodal contrastive learning*) theo phong cách CLIP (Radford et al., 2021) đã trở thành nền tảng chủ đạo cho bài toán này. Các phương pháp như ConVIRT (Zhang et al., 2022) và GLoRIA (Huang et al., 2021) huấn luyện mô hình sao cho các cặp ảnh–báo cáo cùng bệnh nhân (*positive pairs*) được đẩy lại gần nhau, trong khi các cặp khác bệnh nhân (*negative pairs*) bị đẩy xa.

Vấn đề âm tính sai (False Negatives). Trong y khoa, bệnh nhân khác nhau thường có cùng biểu hiện bệnh lý. Hình 1 minh họa tình huống này: ảnh X-quang và báo cáo của hai bệnh nhân độc lập nhưng cùng mắc *Atelectasis* lại bị hàm mất mát đối sánh coi là cặp âm tính và phạt chúng ra xa nhau. Điều này tạo ra gradient sai lệch và làm hỏng khả năng truy hồi theo ngữ nghĩa lâm sàng của mô hình.



Hình 1: Vấn đề âm tính sai trong học đối sánh y khoa. Hai bệnh nhân khác nhau nhưng cùng nhóm bệnh lý bị InfoNCE chuẩn coi là negative. Phương pháp đề xuất gán nhãn soft positive dựa trên mức độ tương đồng bệnh lý.

Đóng góp chính của bài báo này:

- (i) Xây dựng pipeline truy hồi cấp độ study (*study-level*) cho bộ dữ liệu IU-Xray, kết hợp tổng hợp đa view bằng *attention pooling* (frontal + lateral).
- (ii) Thiết kế hàm mất mát cụm bệnh theo phân cấp (*hierarchical clustering loss*) dùng Jaccard có trọng số IDF để tạo nhãn mềm dựa trên mức độ tương đồng bệnh lý.
- (iii) Đề xuất hàm mất mát đối sánh có giám sát lâm sàng (*clinical supervised contrastive loss*) với lịch curriculum, kéo các cặp cùng bệnh khác bệnh nhân lại gần nhau mà không làm suy yếu truy hồi chính xác.

- (iv) Xây dựng bộ chỉ số đánh giá ba cấp độ: *strict*, *cluster*, và *clinical-valid*, trong đó *clinical-valid* R@K là chỉ số chính đo hiệu quả giảm thiểu âm tính sai.

Phần còn lại của bài báo được tổ chức như sau: Mục 2 tổng hợp các công trình liên quan; Mục 3 mô tả phương pháp đề xuất; Mục 4 trình bày thiết lập thực nghiệm; Mục 5 báo cáo kết quả; Mục 6 thảo luận; Mục 7 kết luận.

2 Công Trình Liên Quan (Related Work)

2.1 Học Đối Sánh Đa Phương Thức

CLIP (Radford et al., 2021) khởi đầu xu hướng huấn luyện ảnh và văn bản trong không gian nhúng chung bằng hàm InfoNCE (Oord et al., 2018) trên 400 triệu cặp ảnh–chú thích web. Với dữ liệu y khoa, ConVIRT (Zhang et al., 2022) là công trình tiên phong áp dụng học đối sánh cho ảnh X-quang và báo cáo lâm sàng. GLORIA (Huang et al., 2021) mở rộng bằng cách thêm học cục bộ vùng chú ý (*local attention*). BiomedCLIP (Zhang et al., 2023) huấn luyện trên 15 triệu cặp ảnh–văn bản sinh y học quy mô lớn từ PMC.

2.2 Vấn Đề Âm Tính Sai

Vấn đề âm tính sai đã được nghiên cứu trong học đối sánh tổng quát. Khosla et al. (2020) đề xuất *Supervised Contrastive Loss* (SupCon) sử dụng nhãn lớp để xác định nhiều dương tính trong mỗi batch. Chuang et al. (2020) đề xuất ước lượng phân phối âm tính không thiên lệch. Robinson et al. (2021) nghiên cứu khai thác âm tính khó (*hard negative mining*) kết hợp tránh âm tính sai.

Trong y khoa, vấn đề này đặc biệt nghiêm trọng do: (1) nhiều bệnh nhân chia sẻ cùng bệnh lý, (2) dữ liệu có xu hướng mất cân bằng nhãn nặng (*e.g.* IU-Xray có 57.88% ca bình thường), và (3) ngữ nghĩa bệnh lý phụ thuộc vào cả biểu hiện hình ảnh lẫn mô tả ngôn ngữ lâm sàng.

2.3 Bộ Mã Hóa Y Khoa


SwinV2 (Liu et al., 2022) mở rộng *Swin Transformer* với kỹ thuật rescaling hậu lớp chuẩn hóa và bias tương đối liên tục (*continuous relative position bias*), cho phép fine-tune từ độ phân giải thấp lên cao. Bio_ClinicalBERT (Alsentzer et al., 2019) là mô hình ngôn ngữ BERT được tiền huấn luyện trên ghi chú bệnh viện MIMIC-III, phù hợp với đặc thù ngôn ngữ lâm sàng.

2.4 Truy Hồi Ảnh–Báo Cáo X-quang Ngược

Bộ dữ liệu IU-Xray (Demner-Fushman et al., 2016) là bộ dữ liệu chuẩn (*benchmark*) được sử dụng phổ biến nhất cho bài toán tổng hợp báo cáo và truy hồi X-quang ngược. Nhiều nghiên cứu về truy hồi trên IU-Xray dùng chỉ số strict R@K với ground-truth là cặp ảnh–báo cáo của cùng bệnh nhân, chưa xét đến truy hồi theo tương đồng lâm sàng giữa các bệnh nhân khác nhau. Bài báo này đề xuất chỉ số *clinical-valid* R@K để lấp đầy khoảng trống này.

3 Phương Pháp Đề Xuất (Proposed Method)

Hình 2 minh họa tổng thể kiến trúc và luồng huấn luyện.



Hình 2: Kiến trúc tổng thể của mô hình đề xuất. Hai modality ảnh và văn bản được chiếu về không gian nhúng 512 chiều và tính độ tương đồng cosine thông qua nhiệt độ học được. Hàm mất mát kết hợp ba thành phần.

3.1 Biểu Diễn Dữ Liệu

Mỗi mẫu dữ liệu trong IU-Xray tương ứng với một *study* (lần khám) của một bệnh nhân, gồm:

- **Ảnh:** tối đa một ảnh frontal và một ảnh lateral, kích thước 384×384 pixel sau khi padding để giữ toàn bộ trường nhìn.
- **Văn bản:** báo cáo sau xử lý, ghép từ hai trường *findings* và *impression*.

- **Nhãn bệnh lý:** vector $\mathbf{d} \in \{0, 1\}^{12}$ biểu diễn 12 nhóm bệnh lý theo CheXpert (Irvin et al., 2019), trích xuất bằng quy tắc *keyword matching* xét phủ định (*negation-aware*). Vector này không bao gồm “No Finding” và gộp “Enlarged Cardiomedastinum” vào “Cardiomegaly” theo phép max.

Định nghĩa bình thường (Normal): Sample được coi là *bình thường (normal)* khi $\sum_k d_k = 0$, tức không có nhãn bệnh lý nào bằng 1.

3.2 Kiến Trúc Mô Hình

3.2.1 Bộ Mã Hóa Ảnh (Image Encoder)

Mô hình sử dụng **SwinV2-Base** (Liu et al., 2022) phiên bản `microsoft/swinv2-base-patch4-window7` được tiền huấn luyện trên ImageNet-22K và fine-tune từ độ phân giải 192 lên 384. Đầu vào là ảnh $384 \times 384 \times 3$; đầu ra là `pooler_output` có chiều $\mathbb{R}^{1024}$. Gradient checkpointing được bật để tiết kiệm VRAM.

3.2.2 Bộ Mã Hóa Văn Bản (Text Encoder)

Mô hình sử dụng **Bio_ClinicalBERT** (Alsentzer et al., 2019) (`emilyalsentzer/Bio_ClinicalBERT`) được tiền huấn luyện trên ghi chú bệnh viện MIMIC-III. Báo cáo được cắt tối đa 128 token; embedding đầu ra là token [CLS] từ lớp ẩn cuối, chiều $\mathbb{R}^{768}$.

3.2.3 Đầu Chiếu (Projection Head)

Cả hai modality đều đi qua MLP 2 lớp với cùng cấu trúc:

$$\mathbf{z} = \frac{\text{MLP}(\mathbf{h})}{\|\text{MLP}(\mathbf{h})\|_2}, \quad (1)$$

trong đó MLP được định nghĩa:

$$\text{MLP}(\mathbf{h}) = \mathbf{W}_2 \cdot \text{Dropout}(\text{GELU}(\text{BN}(\mathbf{W}_1 \mathbf{h} + \mathbf{b}_1))) + \mathbf{b}_2, \quad (2)$$

với $\mathbf{W}_1 \in \mathbb{R}^{1024 \times d_{\text{in}}}$, $\mathbf{W}_2 \in \mathbb{R}^{512 \times 1024}$, Dropout tỉ lệ 0.2, và BN là Batch Normalization. Đầu ra $\mathbf{z} \in \mathbb{R}^{512}$ được chuẩn hóa L2.

Độ tương đồng giữa cặp image–text được tính bằng tích vô hướng có nhiệt độ:

$$s_{ij} = e^\tau \cdot \mathbf{z}_I^{(i)\top} \mathbf{z}_T^{(j)}, \quad (3)$$

trong đó τ là tham số học được (*logit_scale*), được kẹp sao cho $e^\tau \in [1, 100]$.

3.2.4 Tổng Hợp Đa View (Multi-View Attention Pooling)

Mỗi view (frontal/lateral) được mã hóa riêng bởi SwinV2 và projection head. Sau đó, một *view-type embedding* $\mathbf{e}_{\text{type}} \in \mathbb{R}^{512}$ (4 loại: frontal, lateral, other, pad) được cộng vào embedding của view tương ứng. Embedding study-level được tính bằng *attention pooling*:

$$\alpha_k = \frac{\exp(a(\mathbf{z}_k + \mathbf{e}_k^{\text{type}}))}{\sum_{k'} \exp(a(\mathbf{z}_{k'} + \mathbf{e}_{k'}^{\text{type}}))}, \quad (4)$$

$$\mathbf{z}_I = \sum_{k=1}^K \alpha_k \mathbf{z}_k, \quad (5)$$

trong đó $a(\cdot) = \mathbf{w}_2^\top \text{GELU}(\mathbf{W}_1 \cdot)$ là mạng attention nhỏ với $\mathbf{W}_1 \in \mathbb{R}^{256 \times 512}$ và $\mathbf{w}_2 \in \mathbb{R}^{256}$; $K \leq 2$ là số view hợp lệ (bị che bởi *view_mask*). Thiết kế này cho phép mô hình tự học tầm quan trọng của từng view thay vì dùng hợp trung bình cứng.

3.2.5 Đầu Phụ Bệnh Lý (Auxiliary Pathology Heads)

Ngoài đầu chiếu chính, mô hình có bốn đầu phụ (MLP một lớp):

- `img_pathology_head`: dự đoán 12 nhãn bệnh lý từ $\mathbf{z}_I$.
- `img_normal_head`: dự đoán nhị phân bình thường/bất thường.
- `txt_pathology_head` và `txt_normal_head`: tương tự từ $\mathbf{z}_T$.

Các đầu phụ ép embedding giữ thông tin bệnh lý, nhưng trọng số nhỏ ($w_a = 0.02$) để không lấn át mục tiêu truy hồi.

3.3 Hàm Mất Mát Theo Phân Cấp Cụm Bệnh

3.3.1 Giai Đoạn 1: MultiPositive InfoNCE (Epoch 1–11)

Trước khi bật clustering, hàm mất mát chính là InfoNCE đa dương tính:

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{j=1}^N \exp(s_{ij})}, \quad (6)$$

trong đó s_{ij} theo công thức (3) đã tích hợp nhiệt độ học được, nên không cần chia thêm. Hàm mất mát tính theo cả hai chiều i2t và t2i; ground-truth dương tính là cặp cùng `patient_id`.

3.3.2 Giai Đoạn 2: Hierarchical Clustering Loss (Epoch 12+)

Từ epoch thứ 12, ground-truth được điều chỉnh thành nhãn mềm (*soft target*) kết hợp giữa khớp chính xác và tương đồng bệnh lý:

$$t_{ij} = (1 - \alpha) \cdot \mathbb{I}[p_i = p_j] + \alpha \cdot S_{ij}^{\text{IDF}}, \quad (7)$$

với $\alpha = 0.35$ và S_{ij}^{IDF} là độ tương đồng Jaccard có trọng số IDF giữa hai vector bệnh lý $\mathbf{d}_i$ và $\mathbf{d}_j$:

$$S^{\text{IDF}}(A, B) = \frac{\sum_{k=1}^{12} w_k \cdot \min(A_k, B_k)}{\sum_{k=1}^{12} w_k \cdot \max(A_k, B_k)}, \quad (8)$$

trong đó trọng số IDF được tính:

$$w_k = \frac{\log(1/f_k)}{\sum_{k'} \log(1/f_{k'})}, \quad (9)$$

với f_k là tần suất xuất hiện của bệnh k trong tập huấn luyện. Thiết kế này ưu tiên bệnh hiếm gặp hơn: *e.g.* Pneumothorax ($f = 2.03\%$) và Fracture ($f = 1.82\%$) có w_k lớn hơn Cardiomegaly ($f = 9.00\%$).

Xử lý nhóm bình thường: Khi $\sum_k d_k^{(i)} = 0$ và $\sum_k d_k^{(j)} = 0$ (cả hai đều bình thường), Jaccard không xác định được. Vì vậy, công thức (7) thêm phần thưởng cố định:

$$S_{ij}^{\text{IDF}} \leftarrow S_{ij}^{\text{IDF}} + 0.4 \cdot \mathbb{I}[\text{normal}(i)] \cdot \mathbb{I}[\text{normal}(j)], \quad (10)$$

giúp nhóm các ca bình thường lại gần nhau trong không gian nhúng.

3.3.3 Hàm Mất Mất Đối Sánh Có Giám Sát Lâm Sàng (Epoch 15+)

Đây là đóng góp cốt lõi nhắm trực tiếp vào vấn đề âm tính sai:

Mặt nạ lâm sàng (Clinical mask):

$$M_{ij}^{\text{clin}} = \underbrace{\mathbb{I}[\mathbf{d}_i \cdot \mathbf{d}_j > 0]}_{\text{có disease overlap}} \cdot \underbrace{\mathbb{I}[i \neq j]}_{\text{khác sample}} \cdot \underbrace{\mathbb{I}[\text{non-normal}(i)]}_{\text{không bình thường}} \cdot \underbrace{\mathbb{I}[\text{non-normal}(j)]}_{\text{không bình thường}} \quad (11)$$

Mặt nạ này xác định các cặp bệnh nhân khác nhau, cùng có ít nhất một bệnh lý chung và đều không bình thường.

Hàm mất mát:

$$\mathcal{L}_{\text{clin}} = -\frac{1}{|\mathcal{Q}|} \sum_{i \in \mathcal{Q}} \frac{1}{|P_i|} \sum_{j \in P_i} \log \frac{\exp(s_{ij})}{\sum_{k=1}^N \exp(s_{ik})}, \quad (12)$$

trong đó $\mathcal{Q} = \{i : |P_i| > 0\}$ là tập query bất thường có ít nhất một positive lâm sàng, và $P_i = \{j : M_{ij}^{\text{clin}} = 1\}$. Hàm mất mát được tính theo cả hai chiều image→text và text→image.

3.3.4 Hàm Mất Mát Phụ (Auxiliary Loss)

$$\mathcal{L}_{\text{aux}} = \frac{1}{4} [\text{BCE}(\hat{\mathbf{d}}_I, \mathbf{d}) + \text{BCE}(\hat{n}_I, n) + \text{BCE}(\hat{\mathbf{d}}_T, \mathbf{d}) + \text{BCE}(\hat{n}_T, n)] + 0.25 \cdot [\text{MSE}(\sigma(\hat{\mathbf{d}}_I), \sigma(\mathbf{d}_T)) + \text{MSE}(\sigma(\hat{n}_I), \sigma(n_T))] \quad (13)$$

trong đó $\hat{\mathbf{d}}$ là dự đoán bệnh lý, $\hat{n}$ là dự đoán bình thường, và $\sigma(\cdot)$ là sigmoid. Thành phần MSE ép hai modality nhất quán về dự đoán bệnh lý.

Hàm mất mát tổng:

$$\mathcal{L} = \mathcal{L}_{\text{base}} + w_c(e) \cdot \mathcal{L}_{\text{clin}} + w_a \cdot \mathcal{L}_{\text{aux}}, \quad (14)$$

với $w_a = 0.02$ và $w_c(e)$ là lịch curriculum phụ thuộc epoch e .

3.4 Lịch Curriculum Lâm Sàng

Thay vì bật $\mathcal{L}_{\text{clin}}$ mạnh ngay từ đầu—có thể kéo mô hình về cụm quá rộng trước khi học được khớp chính xác—bài báo này áp dụng lịch học tăng dần rồi giảm:

$$w_c(e) = \begin{cases} 0 & e < 15 \\ 0.03 + 0.09 \cdot \frac{e - 15}{25 - 15} & 15 \leq e \leq 25 \\ 0.12 & 26 \leq e \leq 60 \\ 0.08 & 61 \leq e \leq 105 \\ 0.04 & 106 \leq e \leq 150 \end{cases} \quad (15)$$

Bảng 1 tóm tắt ý nghĩa từng giai đoạn.

Bảng 1: Lịch curriculum lâm sàng và mục tiêu từng giai đoạn.

Epoch	Mục tiêu chính	w_c	Pha huấn luyện
1–5	Chỉ huấn luyện đầu chiếu (backbone đóng băng)	0.00	Warm-up
6–11	MultiPositive InfoNCE, mở toàn bộ backbone	0.00	Strict alignment
12–14	Bật clustering soft target	0.00	Clustering phase
15–25	Tăng dần clinical loss	$0.03 \rightarrow 0.12$	Clinical ramp
26–60	Clinical supervision đỉnh	0.12	Clinical peak
61–105	Giảm dần clinical để hồi phục strict	0.08	Clinical decay
106–150	Giai đoạn cuối, giảm thêm clinical	0.04	Fine-tune strict

Kết quả thực nghiệm (Mục 5) xác nhận tính hợp lý của lịch này: strict R@1 đạt đỉnh tại epoch 120 sau khi clinical weight giảm, trong khi clinical-valid đạt đỉnh tại epoch 90 khi clinical weight vẫn còn cao.

4 Thực Nghiệm (Experiments)

4.1 Bộ Dữ Liệu

Bộ dữ liệu **IU-Xray** (Demner-Fushman et al., 2016) (Indiana University Chest X-ray Collection) gồm ảnh X-quang ngực chụp từ hệ thống PACS bệnh viện Indiana, kèm theo báo cáo lâm sàng tiếng Anh đã ẩn danh.

Tiền xử lý:

- Ảnh được chuyển sang RGB, padding thành hình vuông bằng nền đen, rồi lưu ở kích thước 384×384 để tương thích với SwinV2-Base. Padding được ưu tiên hơn crop để bảo toàn toàn bộ trường nhìn lâm sàng.
- Văn bản: ghép **findings** + **impression**, chuẩn hóa chữ thường, loại bỏ placeholder và thông tin nhân khẩu, lọc báo cáo dưới 10 từ.
- Nhãn bệnh lý: 14 nhãn CheXpert được tạo bằng quy tắc keyword matching xét phủ định, sau đó rút gọn thành vector 12 chiều.

Bảng 2 thống kê dữ liệu sau xử lý.

Bảng 2: Thống kê bộ dữ liệu IU-Xray sau tiền xử lý.

Thông số	Giá trị	
Tổng số ảnh (PNG, 384×384)	7,322	
Số bệnh nhân / study ID duy nhất	3,772	
Số báo cáo duy nhất	3,018	
Số từ (min / trung bình / max)	10 / 37.27 / 223	
Projection	Frontal	3,738
	Lateral	3,584
Phân chia dữ liệu (seed=42, patient-stratified)		
Huấn luyện (train) – study-level	3,018	
Kiểm định (val) – study-level	377	
Kiểm tra (test) – study-level	377	

Phân bố nhãn bệnh lý được trình bày trong Bảng 3.

Bảng 3: Phân bố 14 nhãn CheXpert trong tập dữ liệu IU-Xray (7,322 ảnh).

Nhãn bệnh lý	Số lượng	Tỉ lệ (%)
No Finding	4,238	57.88
Cardiomegaly	659	9.00
Lung Lesion	1,014	13.85
Lung Opacity	942	12.87
Atelectasis	732	10.00
Consolidation	402	5.49
Pleural Effusion	415	5.67
Support Devices	224	3.06
Edema	185	2.53
Pneumonia	164	2.24
Pneumothorax	149	2.03
Fracture	133	1.82
Pleural Other	65	0.89
Enlarged Cardiomediastinum	17	0.23

4.2 Cài Đặt Thực Nghiệm

Phần cứng: NVIDIA A100 40 GB, Python 3.x, PyTorch, HuggingFace Transformers. Mixed precision (`torch.amp.autocast + GradScaler`).

Các siêu tham số chính được tóm tắt trong Bảng 4.

Bảng 4: Siêu tham số huấn luyện của mô hình v8 (run chính).

Siêu tham số	Giá trị
Số epoch	150
Batch size	32
Gradient accumulation	4
Effective batch size	128
Epoch đóng băng backbone	5
Learning rate (image encoder)	1×10^{-5}
Learning rate (text encoder)	1×10^{-4}
Learning rate (projection head)	2×10^{-4}
Weight decay	0.01
Max gradient norm	1.0
Optimizer	AdamW
LR Scheduler (sau unfreeze)	Linear warmup (5%) + CosineAnnealing
$\eta_{\min}$	10^{-8}
α (soft target blend)	0.35
Temperature (cluster)	1.0
w_a (auxiliary weight)	0.02
Seed	42

Chiến lược checkpoint: Mô hình lưu ba loại checkpoint trong quá trình huấn luyện: (1) **best.pt**: epoch có *strict* R@1 validation cao nhất; (2) **best_balanced.pt**: epoch tối ưu hóa *strict* + $0.1 \cdot \text{clinical-valid}$ khi *strict* $\geq 4.0\%$; (3) **best_clinical_valid.pt**: epoch có *clinical-valid* R@1 validation cao nhất khi *strict* $\geq 3.5\%$. Checkpoint chính được báo cáo là **best.pt** (epoch 120).

4.3 Chỉ Số Đánh Giá

Đánh giá ở cấp độ study: mỗi bệnh nhân là một query, embedding study được tính bằng attention pooling giống lúc huấn luyện.

(M1) Strict Retrieval: Ground truth $G_{ij}^{\text{strict}} = \mathbb{1}[p_i = p_j]$, tức chỉ đúng bệnh nhân mới được tính là hit. Đây là chỉ số khó nhất, đo khớp chính xác. Báo cáo R@1, R@5, R@10, MRR theo cả hai chiều i2t và t2i.

(M2) Cluster Retrieval: $G_{ij}^{\text{clus}} = \mathbb{1}[\mathbf{d}_i \cdot \mathbf{d}_j > 0] + \mathbb{1}[\text{normal}(i) \wedge \text{normal}(j)]$. Đo

retrieval theo cụm bệnh rộng, bao gồm cả cặp bình thường–bình thường.

(M3) Clinical-Valid Retrieval (Chỉ số chính): $G_{ij}^{\text{clin}} = \mathbb{K}[\mathbf{d}_i \cdot \mathbf{d}_j > 0] \wedge \mathbb{K}[\text{non-normal}(i)] \wedge \mathbb{K}[\text{non-normal}(j)]$. Chỉ tính metric trên các query *non-normal* có ít nhất một positive lâm sàng trong tập kiểm tra ($n = 147$ query mỗi chiều). Đây là chỉ số đo trực tiếp mục tiêu giảm âm tính sai.

(M4) Clinical-All Retrieval: Tương tự M3 nhưng tính trên tất cả 377 query (kể cả query không có positive lâm sàng). Dùng làm chỉ số phụ.

Phân tích định tính (Bucket Analysis): Mỗi kết quả top-1 được phân vào một trong bốn nhóm:

- *Strict hit*: top-1 đúng bệnh nhân.
- *Clinical rescue*: top-1 khác bệnh nhân nhưng đúng clinical mask.
- *Cluster rescue*: top-1 đúng cluster mask nhưng không đủ chuẩn clinical.
- *Miss*: top-1 không thuộc nhóm nào ở trên.

5 Kết Quả (Results)

5.1 Kết Quả Định Lượng Trên Tập Kiểm Tra

Bảng 5 trình bày kết quả đầy đủ của **v8 (epoch 120, best.pt)** trên tập kiểm tra 377 study.

Bảng 5: Kết quả truy hồi trên tập kiểm tra IU-Xray. **i2t**: image-to-text; **t2i**: text-to-image; **Mean**: trung bình hai chiều. Metric chính: *clinical-valid* R@1 (in đậm). Checkpoint: **best.pt**, epoch 120.

	Strict			Cluster			Clinical-Valid		
	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
i2t	3.45	10.08	17.77	68.17	79.58	85.15	49.66	60.54	69.39
t2i	4.24	12.20	18.83	70.56	97.08	99.20	70.07	95.24	97.96
Mean	3.85	11.14	18.30	69.36	88.33	92.18	59.86	77.89	83.67

$MRR(\text{strict}) = 9.01\%$; $\text{clinical-all mean R@1} = 23.34\%$; $\text{clinical-valid: } 147/377$ query mỗi chiều có positive.

Kết quả tập kiểm định (Validation, epoch 120):

- Strict R@1 (mean) tốt nhất: **4.91%** tại epoch 120.
- Clinical-valid R@1 (mean) tốt nhất: **52.11%** tại epoch 90.
- Cluster R@1 (mean) tốt nhất: **65.25%** tại epoch 40.

5.2 Phân Tích Định Tính: Bucket Analysis

Bảng 6 phân tích top-1 của 377 study kiểm tra.

Bảng 6: Phân tích định tính top-1 trên 377 study kiểm tra. *Clinical rescue* là các ca mô hình trả về kết quả khác bệnh nhân nhưng đúng về nhóm bệnh lý — minh chứng trực tiếp cho hiệu quả giảm âm tính sai.

Chiều	Strict Hit	Clinical Rescue	Cluster Rescue	Miss
Image → Text	13 (3.4%)	64 (17.0%)	180 (47.7%)	120 (31.8%)
Text → Image	16 (4.2%)	93 (24.7%)	157 (41.6%)	111 (29.4%)
Tổng	29	157	337	231

Tổng cộng **157 ca clinical rescue** (64 i2t + 93 t2i) xác nhận mô hình học được tương đồng lâm sàng vượt qua ranh giới bệnh nhân. Trong 29 ca strict hit, top-1 đúng hoàn toàn bệnh nhân. 337 ca cluster rescue cho thấy mô hình nhóm tốt các ca có cùng cụm bệnh rộng. Chỉ 231/754 ca (30.6%) bị miss hoàn toàn.

5.3 So Sánh Với Mô Hình Nền

Bảng 7 so sánh v8 (mô hình đề xuất) với v7 trên cùng phân chia dữ liệu (seed=42, patient-stratified).

Bảng 7: So sánh v8 (đề xuất) với v7 (*baseline*) trên tập kiểm tra. Cả hai được đánh giá trên cùng phân chia dữ liệu cố định.

Mô hình	Strict Mean R@1	Cluster Mean R@1	Clinical-Valid M
V7 (best-balanced checkpoint)	3.32%	67.37%	59.86%
V8 (best.pt, ep. 120)	3.85%	69.36%	59.86%
<i>Cải thiện (Δ)</i>	+0.53 pp	+1.99 pp	0.00 pp

V8 cải thiện strict mean R@1 thêm **+0.53 pp** và cluster mean R@1 thêm **+1.99 pp** so với v7, trong khi duy trì clinical-valid mean R@1 ở mức 59.86%. Kết quả này cho thấy lịch curriculum của v8 cân bằng tốt hơn giữa truy hồi chính xác và truy hồi lâm sàng so với cài đặt của v7.

5.4 Động Lực Huấn Luyện

Hình 3 minh họa diễn biến các chỉ số qua 150 epoch.

Epoch 1–5:	Chỉ huấn luyện đầu chiếu (backbone đóng băng).
Epoch 6:	Mở backbone; strict R@1 bắt đầu tăng mạnh.
Epoch 12:	Bật clustering loss; cluster R@1 tăng rõ rệt.
Epoch 15:	Bắt đầu tăng w_c ; clinical-valid tăng dần.
Epoch 40:	Cluster R@1 đạt đỉnh validation (65.25%).
Epoch 60:	w_c bắt đầu giảm; strict R@1 phục hồi.
Epoch 90:	Clinical-valid R@1 đạt đỉnh validation (52.11%).
Epoch 120:	Strict R@1 đạt đỉnh validation (4.91%) — checkpoint best.pt.
Epoch 150:	Epoch cuối; strict giảm nhẹ so với epoch 120.

Hình 3: Diễn biến các chỉ số trên tập kiểm định qua 150 epoch. (Hình ảnh thực tế từ `history.csv` nên được vẽ bằng matplotlib.) Điểm đặc trưng: strict đạt đỉnh muộn (epoch 120) sau khi clinical decay, xác nhận hiệu quả của lịch curriculum.

Điểm quan trọng cần nhấn mạnh: strict R@1 **phục hồi rõ ràng** sau khi w_c bắt đầu giảm tại epoch 60, và đạt đỉnh tại epoch 120. Điều này xác nhận giả thuyết thiết kế: clinical decay giúp mô hình “tĩnh chỉnh lại” khả năng khớp chính xác sau giai đoạn học cụm bệnh.

6 Thảo Luận (Discussion)

6.1 Ý Nghĩa Của Clinical-Valid R@1 Cao

Clinical-valid mean R@1 = 59.86% trên 147 query (mỗi chiều) có ít nhất một positive lâm sàng cho thấy mô hình học được tương đồng bệnh lý vượt qua ranh giới bệnh nhân. Trong thực tế lâm sàng, khả năng truy hồi ca tương đồng bệnh lý (dù khác bệnh nhân) hữu ích hơn khớp chính xác—bác sĩ cần ca tham chiếu có biểu hiện giống, không nhất thiết cùng bệnh nhân.

6.2 Hạn Chế Của Strict R@1

Strict R@1 = 3.85% thấp có thể giải thích bởi: (1) IU-Xray nhỏ (3,018 study huấn luyện) tương đối so với độ phức tạp của bài toán; (2) nhiều báo cáo IU-Xray có nội dung rất giống nhau, gây khó khăn cho việc phân biệt chính xác; (3) mô hình đang học đồng thời hai mục tiêu (strict và clinical), tạo đánh đổi (*trade-off*).

6.3 Vai Trò Của Jaccard IDF và Healthy Cluster

Trọng số IDF đảm bảo rằng các bệnh hiếm gặp như Pneumothorax (2.03%) và Fracture (1.82%) đóng góp nhiều hơn vào độ tương đồng so với bệnh phổ biến như Cardiomegaly (9.00%). Điều này phù hợp với thực tế lâm sàng: hai ảnh cùng có Pneumothorax hiếm gặp đáng được xem là tương đồng hơn hai ảnh cùng có Cardiomegaly phổ biến. Nhóm bình thường (57.88% dữ liệu) được xử lý riêng qua phần thưởng 0.4, tránh trường hợp vector zero làm Jaccard không xác định được.

6.4 Curriculum Vs. Fixed Clinical Weight

Lịch curriculum (tăng rồi giảm w_c) được thiết kế để giải quyết bài toán cân bằng: nếu w_c cố định cao, mô hình bị kéo quá mạnh về cụm rộng và không học được khớp chính xác; nếu w_c cố định thấp, lợi ích từ clinical supervision không đủ. Kết quả epoch 120 (best strict) sau giai đoạn decay xác nhận hiệu quả của thiết kế này.

6.5 Các Thành Phần Không Bật Trong V8

Để đảm bảo tính minh bạch khoa học, cần ghi rõ: các thành phần *DualPrototypeBank*, *IntraClusterRankingLoss*, và *Hard Negative Mining* có trong codebase nhưng bị vô hiệu hóa trong run v8 chính (proto_start=999, rank_start=999, mine_start=999). Kết quả báo cáo **không đến từ** các thành phần này. Chúng là hướng mở rộng cho công việc tương lai.

6.6 Hạn Chế

1. **Quy mô dữ liệu:** IU-Xray chỉ có ~3,000 study huấn luyện—nhỏ so với các hệ thống CLIP y khoa hiện đại dùng hàng triệu cặp.
2. **Nhãn bệnh lý yếu:** Nhãn được tạo bằng keyword matching, không phải annotation của bác sĩ. Một số nhãn có thể sai do xử lý phủ định đơn giản.
3. **Không có baseline từ paper khác:** Chưa so sánh với ConVIRT, GLoRIA, BiomedCLIP trên cùng phân chia dữ liệu, do không có cài đặt mã nguồn mở phù hợp.
4. **Chỉ đánh giá trên IU-Xray:** Khả năng tổng quát hóa sang MIMIC-CXR hay các bộ dữ liệu X-quang khác chưa được kiểm chứng.
5. **Cluster metric bị ảnh hưởng bởi nhóm bình thường:** Cluster R@1 cao một phần do nhóm normal lớn (57.88%) tạo nhiều true positive dễ.

7 Kết Luận (Conclusion)

Bài báo đề xuất **khung học đối sánh có hướng dẫn cụm bệnh** (*clustering-guided contrastive learning framework*) cho bài toán truy hồi ảnh–báo cáo X-quang ngực, với mục tiêu giảm thiểu vấn đề âm tính sai trong học đối sánh y khoa. Mô hình kết hợp SwinV2-Base và Bio_ClinicalBERT, tổng hợp đa view bằng attention pooling, và huấn luyện theo ba giai đoạn với lịch curriculum lâm sàng.

Trên IU-Xray với phân chia patient-stratified cố định (seed=42):

- *Clinical-valid* mean R@1 = **59.86%** (chỉ số chính, 147 query/chiều).
- *Cluster* mean R@1 = **69.36%**.
- *Strict* mean R@1 = **3.85%**; MRR = 9.01%.
- **157 ca clinical rescue** trong top-1 (64 i2t + 93 t2i) từ 377 study kiểm tra.

Kết quả cho thấy phương pháp đề xuất học được tương đồng lâm sàng hiệu quả, phù hợp với mục tiêu giảm âm tính sai. Strict retrieval còn là hạn chế cần tiếp tục cải thiện, đặc biệt bằng cách thêm dữ liệu lớn hơn hoặc ablation có hệ thống hơn. Hướng nghiên cứu tương lai bao gồm: (1) ablation loại từng thành phần (IDF Jaccard, healthy cluster, curriculum schedule), (2) tích hợp hard negative mining, (3) đánh giá trên MIMIC-CXR quy mô lớn hơn, và (4) so sánh với baseline đã published trên cùng phân chia dữ liệu.

Lời Cảm Ơn

Tác giả cảm ơn giáo viên hướng dẫn và các thành viên nhóm nghiên cứu đã có những góp ý quý báu. Thực nghiệm được thực hiện trên NVIDIA A100 thông qua Google Colaboratory và nền tảng Kaggle.

Tài liệu

Alsentzer, E., Murphy, J. R., Boag, W., Weng, W.-H., Jin, D., Naumann, T., and McDermott, M. (2019). Publicly available clinical BERT embeddings. In *Proceedings of the 2nd Clinical Natural Language Processing Workshop*, pp. 72–78. Association for Computational Linguistics.

Chuang, C.-Y., Robinson, J., Lin, Y.-C., Torralba, A., and Jegelka, S. (2020). Debiased contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 33, pp. 8765–8775.

- Demner-Fushman, D., Kohli, M. D., Rosenman, M. B., Shooshan, S. E., Rodriguez, L., Antani, S., Thoma, G. R., and McDonald, C. J. (2016). Preparing a collection of radiology examinations for distribution and retrieval. *Journal of the American Medical Informatics Association (JAMIA)*, 23(2):304–310.
- Huang, S.-C., Shen, L., Lungren, M. P., and Yeung, S. (2021). GloRIA: A multimodal global-local representation learning framework for label-efficient medical image recognition. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 3942–3951.
- Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Ilcus, S., Chute, C., Marklund, H., Haghighi, B., Ball, R., Shpanskaya, K., et al. (2019). CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 33, pp. 590–597.
- Jing, B., Xie, P., and Xing, E. (2018). On the automatic generation of medical imaging reports. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 2577–2586.
- Khosla, P., Tian, Y., Wang, X., Liu, C., Isola, P., Krishnamurthy, A., and Tian, Y. (2020). Supervised contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 33, pp. 18661–18673.
- Liu, Z., Hu, H., Lin, Y., Yao, Z., Xie, Z., Wei, Y., Ning, J., Cao, Y., Zhang, Z., Dong, L., et al. (2022). Swin transformer V2: Scaling up capacity and resolution. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 12009–12019.
- Oord, A. v. d., Li, Y., and Vinyals, O. (2018). Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., et al. (2021). Learning transferable visual models from natural language supervision. In *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 8748–8763.
- Robinson, J., Chuang, C.-Y., Sra, S., and Jegelka, S. (2021). Contrastive learning with hard negative samples. In *International Conference on Learning Representations (ICLR)*.
- Zhang, Y., Jiang, H., Miura, Y., Manning, C. D., and Langlotz, C. P. (2022). Contrastive learning of medical visual representations from paired images and text. In *Machine Learning for Healthcare Conference (MLHC)*, pp. 2–25.

Zhang, S., Xu, Y., Usuyama, N., Bagga, J. K., Tinn, R., Preston, S., Rao, R., Wei, M., Valluri, N., Wong, C., et al. (2023). Large-scale domain-specific pretraining for biomedical vision–language processing. *arXiv preprint arXiv:2303.00915*.

A Cấu Hình Đầy Đủ Run V8

Bảng 8: Toàn bộ cấu hình siêu tham số của run v8 chính (v8_curriculum_a100_150ep_seed42_bs32_v1).

Tham số	Giá trị
<i>Cơ bản</i>	
epochs	150
batch_size	32
grad_accum	4
effective_batch	128
freeze_ep	5
eval_every	5
seed	42
num_workers	4
<i>Learning rate</i>	
lr_head (projection head)	2e-4
lr_enc (image encoder)	1e-5
lr_text (text encoder)	1e-4
weight_decay	0.01
max_grad_norm	1.0
<i>Clustering</i>	
cluster_start	12
CLUSTER_ALPHA	0.35
proto_start	999 (vô hiệu hóa)
rank_start	999 (vô hiệu hóa)
mine_start	999 (vô hiệu hóa)
<i>Clinical curriculum</i>	
clinical_start	15
clinical_ramp_start_weight	0.03
clinical_peak_weight	0.12
clinical_ramp_end	25
clinical_hold_end	60
clinical_mid_weight	0.08
clinical_decay_end	105
clinical_final_weight	0.04
clinical_best_min_strict	3.5
<i>Trọng số loss</i>	
aux_weight	0.02
rank_weight	0.0

B Phân Bố Trọng Số IDF Theo Nhóm Bệnh

Bảng 9 tính trọng số IDF theo công thức (9) từ tần suất trong Bảng 3 (bỏ “No Finding” và gộp “Enlarged Cardiomediatinum” vào “Cardiomegaly”).

Bảng 9: Trọng số IDF tương đối của 12 nhóm bệnh trong vector bệnh lý. Bệnh hiếm gặp (Pneumothorax, Fracture, Pleural Other) có trọng số cao hơn bệnh phổ biến (Cardiomegaly, Lung Lesion).

Nhóm bệnh	Tần suất (%)	Trọng số IDF (tương đối)
Pleural Other	0.89	Cao nhất ●●●●●
Fracture	1.82	Rất cao ●●●●
Pneumothorax	2.03	Rất cao ●●●●
Pneumonia	2.24	Cao ●●●●
Edema	2.53	Cao ●●●●
Support Devices	3.06	Vừa ●●
Consolidation	5.49	Vừa ●●
Pleural Effusion	5.67	Vừa ●●
Cardiomegaly	9.00	Thấp ●
Atelectasis	10.00	Thấp ●
Lung Opacity	12.87	Thấp ●
Lung Lesion	13.85	Thấp nhất ·

C Bộ Chỉ Số Đầy Đủ Tất Cả Checkpoint

Bảng 10: So sánh ba loại checkpoint của run v8 trên tập kiểm tra.

Checkpoint	Epoch	Strict Mean R@1	Cluster Mean R@1	Clinical-Valid
best.pt	120	3.85%	69.36%	59.36%
best_balanced.pt	120	3.85%	69.36%	59.36%
best_clinical_valid.pt	90	2.39%	65.78%	59.36%

best.pt và best_balanced.pt trùng kết quả do cùng epoch 120. best_clinical_valid.pt (epoch 90) cho strict thấp hơn rõ rệt trong khi clinical-valid chỉ tăng nhẹ (+0.34 pp), nên không được chọn làm checkpoint chính.